Отчет по второму персональному заданию по курсу **Распознавание и генерация речи**

Ворсин Егор

Оглавление

1. Данные 3
2. Задание 1 4
3. Задание 2 4
4. Задание 3 5
5. Задание 4 6
6. Задание 5 7
7. Задание 6 8
8. Задание 7 12
9. Задание 7b 13
10. Задания 8-9 13

1. Данные

Для выполнения задания использовались данные двух форматов:

1) Аудио – аудиозаписи формата .wav. Использовались датасеты:
    - LibriSpeech – корпус, содержащий приблизительно 1000 часов английской речи, озвученной с частотой 16 кГц, подготовленный Василом Панайотовым при содействии Даниэля Пови. Данные получены из аудиокниг, озвученных в рамках проекта LibriVox, и были тщательно сегментированы и выровнены;
    - Earnings-22 – набор данных представляет собой набор реальных аудиозаписей с акцентом, призванный объединить академические и промышленные исследования. Он содержит 125 файлов, в общей сложности около 119 часов англоязычных конференц-звонков по финансовым результатам компаний из разных стран мира. В набор данных входят полные аудиозаписи, стенограммы и сопутствующие метаданные, такие как биржевой символ, страна головного офиса и определенный авторами «языковой регион».
2) Текст – Текстовые корпусы для обучения LM (задания 8-9). Использовались датасеты:
    - Earnings-22;
    - atrost/financial_phrasebank – sentences_50agree подмножество financial_phrasebank, в соответствии с FinBERT paper;
    - analyst_ratings_processed – собранные данные о рейтингах аналитиков.

2. Задание 1

Имплементация Greedy (жадное декодирование) метода.

Таблица 1. Результаты декодирования методом Greedy

WER	CER
11.219%	3.813%

3. Задание 2

Имплементация метода Beam Search. В рамках задания реализована вариация параметра beam_width отвечающий за «ширину» поиска – то, сколько примеров на этапе «truncate beam» (выбираем топ-beam_width примеров от которых будем ветвиться далее).

Таблица 2. Результаты эксперимента подбора параметра beam_width методом декодирования Beam Search

beam_width	WER	CER
1	11.244%	3.803%
3	11.146%	3.784%
10	11.073%	3.769%
50	11.098%	3.769%

Рисунок 1. Динамика WER и CER в зависимости от beam_width

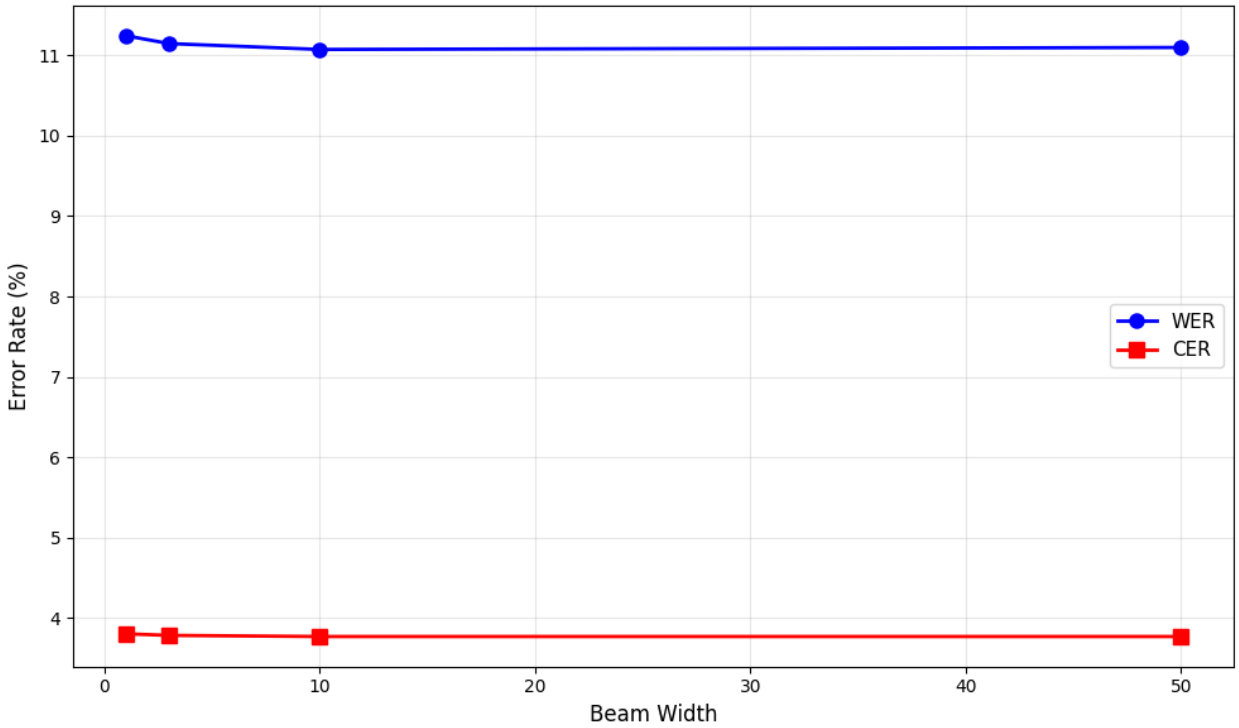

Рис. 2. Динамика времени, затраченного она декодирование, зависимости от beam_width

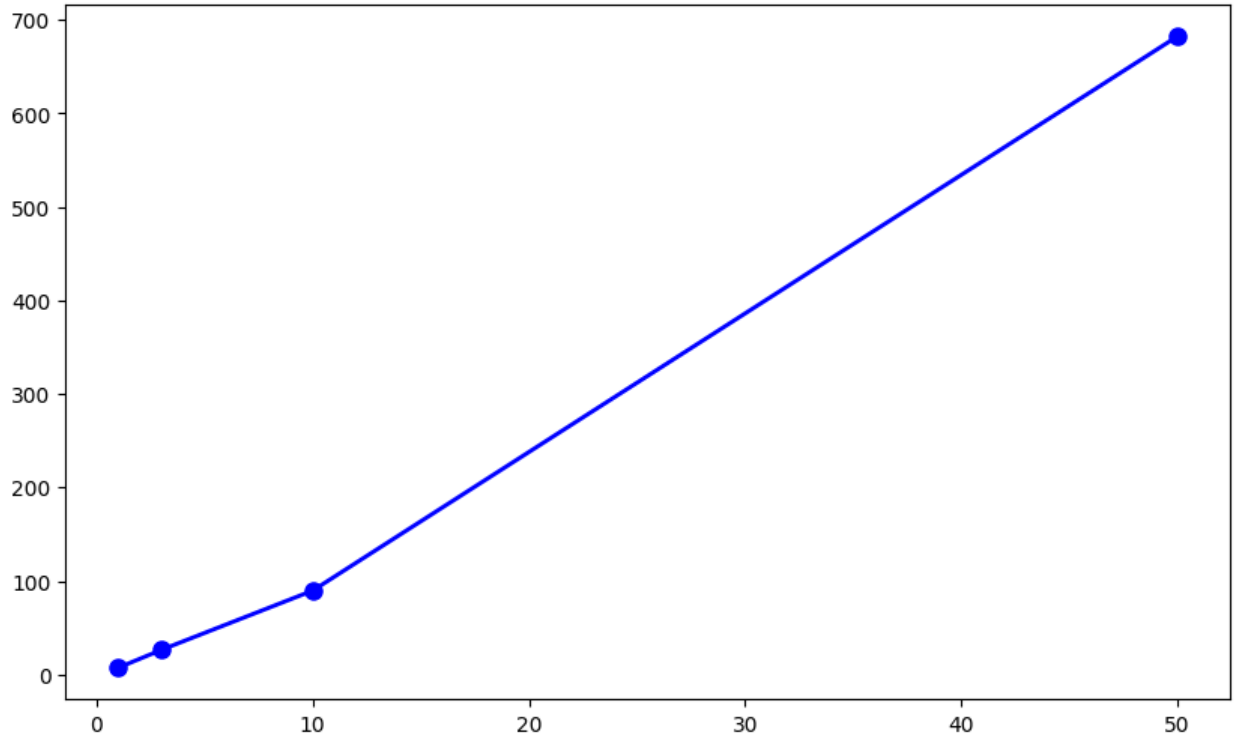

WER и CER уменьшаются при увеличении параметра beam_width, что достаточно очевидно, поскольку мы можем захватить лучший «выход», который могли бы пропустить в жадном методе. Однако при переходе к размеру 50 метрики увеличиваются.
Также исходя из графика на Рис. 1, что время на декодирование растет пропорционально увеличению «ширины» поиска.

Оптимальным значением параметра оказалось 10.

4. Задание 3

Эксперимент с варьированием параметра temperature в методе декодирования greedy. Сетка для варьирования параметра = [0.5, 0.8, 1.0, 1.2, 1.5, 2.0]. В ходе эксперимента все метрики оставались константными: WER = 11.2198%, CER = 3.8128%. Данный результат обуславливается тем, что мы не вносим никаких изменений процесс самого метода. Также все входные данные остаются теми же просто с точностью до константы, по сути мы не поменяли ничего. Деление на температуру изменит значения логитов, однако не изменит их распределение, они в случае ранжирования, они останутся на тех же местах. А поскольку в случае greedy метода просто используется argmax, то и результат останется тот же.

5. Задание 4

Имплементация метода Beam search с использованием LM shallow fusion (далее Beam search LM). Был проведен эксперимент по подбору параметров alpha и beta из формулы:

$$acoustic_score + lm_score \cdot alpha + word_count \cdot beta, \text{ где}$$

$acoustic_score$ - логарифм вероятности того, что последовательность звуков в аудио соответствует конкретной последовательности, lm_score - вероятность последовательности слов, предсказанной N-gram моделью (KenLM), $word_count$ - количество слов в текущей гипотезе.

Сетка параметров для эксперимента: alpha ∈ [0.01, 0.05, 0.1, 0.5, 1.0, 2.0, 5.0], beta ∈ [0.0, 0.5, 1.0, 1.5]. Использовался beam_width = 10.

Таблица 3. Результаты варьирования параметров alpha и beta в методе декодирования Beam Search LM

alpha	beta	WER	CER
0.01	0.5	10.999756%	3.740129%
0.01	0.0	10.999756%	3.759508%
0.10	1.5	10.999756%	3.783731%
0.10	1.0	11.048643%	3.798266%
0.10	0.5	11.073087%	3.803110%
0.05	1.0	11.121975%	3.783731%
0.05	0.5	11.121975%	3.788576%
0.05	0.0	11.195307%	3.793421%
0.05	1.5	11.195307%	3.793421%
0.01	1.0	11.219751%	3.778887%
0.10	0.0	11.244195%	3.807955%
0.01	1.5	11.341970%	3.803110%
0.50	1.5	13.713029%	4.384477%
0.50	1.0	13.859692%	4.394167%
0.50	0.5	14.495233%	4.442614%
0.50	0.0	15.155219%	4.524975%
1.00	1.5	32.168174%	7.862991%
1.00	1.0	35.003667%	8.303861%
1.00	0.5	37.130286%	8.744731%
1.00	0.0	39.305793%	9.122620%
2.00	1.0	92.153508%	29.828981%
2.00	1.5	92.177952%	29.111962%
2.00	0.5	93.155708%	31.529480%
2.00	0.0	94.133464%	33.496439%
5.00	1.5	98.973356%	86.575263%
5.00	1.0	99.144463%	88.096507%
5.00	0.5	99.193351%	89.302844%

5.00	0.0	99.340015%	90.426820%

Рис. 3. Тепловая карта результатов эксперимента варьирования параметров alpha и beta в методе декодирования Beam Search LM

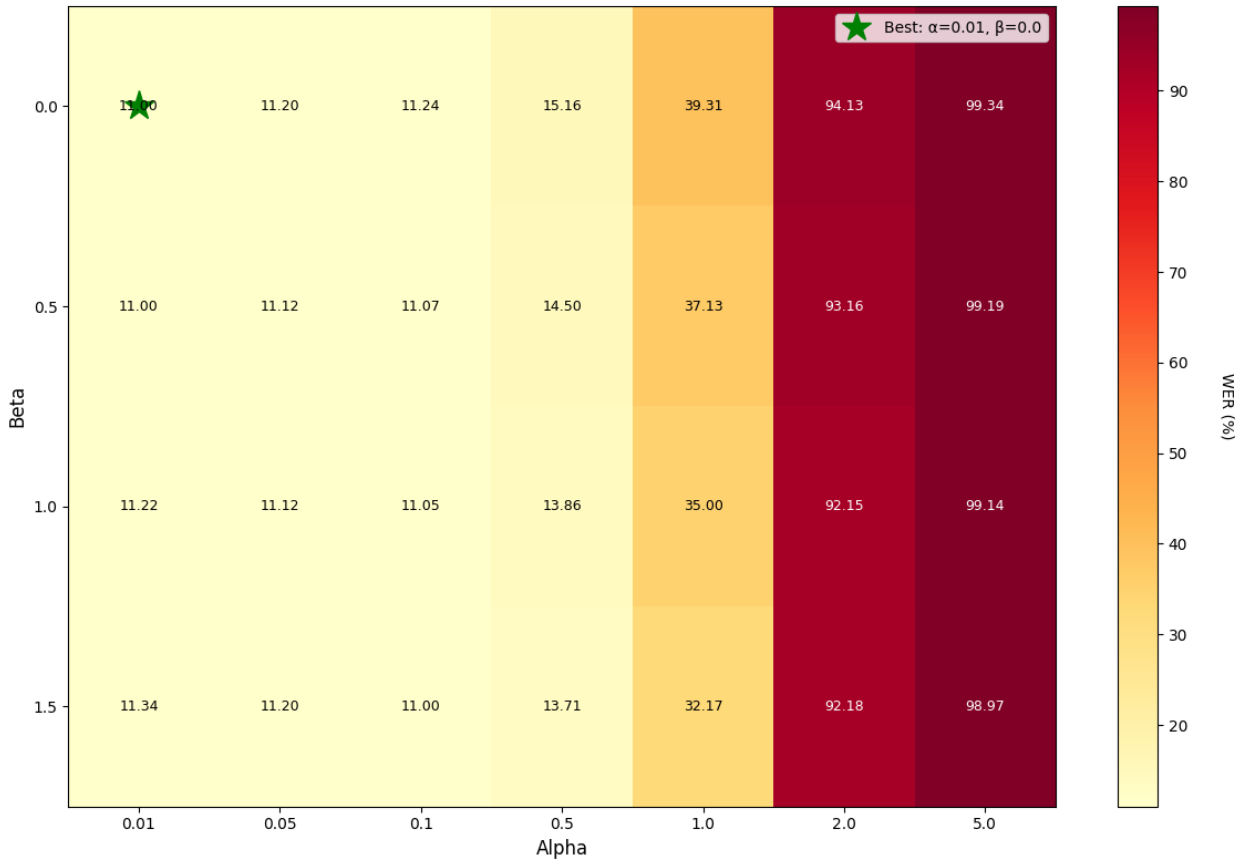

При увеличении параметра alpha метрики заметно увеличиваются: при переходе через alpha = 1.0 метрики значительно от ≈14% до ≈35%. Варьирование параметра beta не оказывает серьезного влияния на результат, в случае alpha ≥ 0.5 увеличение beta улучшает предсказания. Делается вывод о том, что в данной реализации модели нельзя так сильно опираться на предсказания LM-модели.

Лучшими параметрами оказались alpha = 0.01, beta = 0.5 с WER = 10.999756% и CER = 3.740129% (на тепловой карте отмечены параметры alpha = 0.01, beta = 0.0, с данными параметрами WER тот же, но CER больше, чем с alpha = 0.01, beta = 0.5). Данная реализация метода оказалась на 0.0733% лучше по метрике WER, чем просто в методе Beam search.

6. Задание 5

Эксперимент с использованием 4-Gram LM (lm/4-gram.arpa.gz). Декодирование производилось методом Beam search LM с параметрами alpha = 0.01, beta = 0.5, beam_width = 10. По итогу эксперимента WER = 10.9753%, CER = 3.7353%. Заметно улучшение WER, однако метрика CER ухудшилась. Связанно с тем, что модель стала "умнее" в плане грамматики,

но начала чаще игнорировать мелкие акустические детали ради общей логики фразы.

7. Задание 6

Имплементация LM Rescoring - повторная оценка гипотез о пучке с помощью LM. Условия эксперимента те же, что и в задании 4: те же alpha, beta, beam_width, LM.

Таблица 4. Результаты варьирования параметров alpha и beta в методе декодирования Beam Search LM

alpha	beta	WER	CER
0.05	1.5	10.901980%	3.740129%
0.01	1.5	10.999756%	3.749818%
0.01	0.5	10.999756%	3.754663%
0.10	1.5	10.999756%	3.788576%
0.01	0.0	11.048643%	3.769197%
0.10	1.0	11.048643%	3.793421%
0.05	1.0	11.073087%	3.769197%
0.01	1.0	11.097531%	3.764353%
0.05	0.5	11.097531%	3.778887%
0.05	0.0	11.170863%	3.788576%
0.10	0.5	11.170863%	3.832179%
0.10	0.0	11.293082%	3.841868%
0.50	1.5	11.684185%	3.914539%
0.50	1.0	11.733073%	3.909694%
0.50	0.0	11.733073%	3.914539%
0.50	0.5	11.757516%	3.909694%
1.00	1.5	12.050843%	3.967831%
1.00	1.0	12.050843%	3.972676%
1.00	0.0	12.099731%	3.987210%
1.00	0.5	12.124175%	3.987210%
2.00	0.5	12.417502%	4.050191%
2.00	1.0	12.417502%	4.050191%
2.00	1.5	12.417502%	4.050191%
2.00	0.0	12.441946%	4.050191%
5.00	1.5	12.564165%	4.074415%
5.00	0.0	12.613053%	4.079260%
5.00	0.5	12.613053%	4.079260%
5.00	1.0	12.613053%	4.079260%

Лучшие параметры: alpha = 0.05, beta = 1.5 с WER = 10.901980% и CER = 3.740129%. Абсолютное улучшение WER на 0.0978%.

Заметно огромное изменение в динамике метрик. При сильном увеличении обоих параметров метрики не становятся аномально большими и держатся на «нормальном» уровне. В случае shallow fusion при увеличении alpha

модель перебивала акустическую модель и заставляла метод генерировать неподходящие под аудио слова, но подходящие по смыслу. В случае rescoring LM помогает просто помогает выбрать лучший beam, не влияя на его составление. Именно поэтому в данном случае лучшей конфигурацией оказались параметры с большей alpha, чем в shallow fusion.

Примеры, когда, по крайней мере, один метод LM изменяет гипотезу по сравнению с обычным поиском по лучу:

```
REF:  then as archy stood in the dark literally aghast with astonishment he heard the faint rustling once more and again all was silent
BEAM: then as archi stood in the dark literally aghased with astonishment he heard the faint rustling once more and again all was
silent   | error
SF:   then as arche stood in the dark literally aghased with astonishment he heard the faint rustling once more and again all was
silent   | error
RS:   then as arche stood in the dark literally aghased with astonishment he heard the faint rustling once more and again all was
silent   | error

REF:  the kick he had received was a foretaste of what he might expect and after a little consideration he came to the conclusion that his
duty was to escape and get back to the cutter as quickly as he could
BEAM: the kickhe had received was a foretaste of what he might expect and after a little consideration he came to the conclusion that his
duty was to escape and get back to the cutter as quickly as he could   | error
SF:   the kickhe had received was a foretaste of what he might expect and after a little consideration he came to the conclusion that his
duty was to escape and get back to the cutter as quickly as he could   | error
RS:   the kick he had received was a foretaste of what he might expect and after a little consideration he came to the conclusion that his
duty was to escape and get back to the cutter as quickly as he could   | correct

REF:  sympathy and pity for the dwellers in the hoze were completely gone now and he set his teeth fast and mentally called himself a weak
idiot for ever thinking about such people
BEAM: sympathy and pity for the dwellers in the hoes were completely gone now and he set his teeth fast and mentally called himself a weak
idiot for ever thinking about such people   | error
SF:   sympathy and pity for the dwellers in the hoaes were completely gone now and he set his teeth fast and mentally called himself a weak
idiot for ever thinking about such people   | error
RS:   sympathy and pity for the dwellers in the hoaes were completely gone now and he set his teeth fast and mentally called himself a weak
idiot for ever thinking about such people   | error

REF:  a fellow who was shut up in prison for life might do it he said but not in a case like this
BEAM: a fellow who as shut up in prison for life might doit he said but not in a case like this   | error
SF:   a fellow who as shut up in prison for life might do it he said but not in a case like this   | error
RS:   a fellow who as shut up in prison for life might do it he said but not in a case like this   | error
```

```
REF:  the dull sound of departing steps and a low whistling sound coming down through the skylight window into the cabin where archy
raystoke lay with his heavy eyelids pressed down by sleep
BEAM: the dull sound of departing steps and a low whistling sound coming down through the skylight window into the cabin where archy
raystroke lay with his heavy eyelids pressed down by sleep   | error
SF:   the dull sound of departing steps and a low whistling sound coming down through the skylight window into the cabin where archy
raystroke lay with his heavy iyelids pressed down by sleep   | error
RS:   the dull sound of departing steps and a low whistling sound coming down through the skylight window into the cabin where archy
raystroke lay with his heavy iyelids pressed down by sleep   | error

REF:  he swung round walked aft and began sweeping the shore again with his glass while the master and dick exchanged glances which meant a
great deal
BEAM: he swung round walked aff and began sweeping the shore again with his glass while the master and dick exchanged glances which met
agree deal   | error
SF:   he swung round walked aff and began sweeping the shore again with his glass while the master and dick exchanged glances which met a
gree deal   | error
RS:   he swung round walked aff and began sweeping the shore again with his glass while the master and dick exchanged glances which met
agree deal   | error
```

LM лучше всего справляется с восстановлением структуры слов и разрешением пробельных коллизий:

- Пример 2: Beam выдает *kickhe*. RS успешно исправляет это в *the kick he*. Поскольку "kick he" — статистически вероятная последовательность, LM исправляет акустическую ошибку.
- Пример 4: BEAM выдает *doit*. SF и RS исправляют это в *do it*.

Модель плохо распознает редкие слова, в частности имена собственные:

- Пример 1: Имя *archy* превращается в *archi* (Beam), а затем SF/RS меняют его на *arche*. LM не знает имени "Archy" и выбирает наиболее близкое по написанию слово из словаря;
- Пример 5: *archy raystoke* превращается в *raystroke*. Здесь LM «исправляет» редкую фамилию на более частотное английское слово (stroke), создавая ошибку там, где ее могло не быть.

8. Задание 7

Эксперимент по сравнению декодирования модели разными методами на данных, на которых обучались Wav2Vec2 и LM модели (LibriSpeech), и на данных, которые модели не видели (Earnings22) с иным доменом.

Таблица 5. Сравнение метрик в зависимости от метода декодирования и датасета

Метод	LibriSpeech WER	LibriSpeech CER	Earnings22 WER	Earnings22 CER
Greedy	11.219751%	3.812800%	54.969880%	25.578503%
Beam search	11.073087%	3.769197%	54.939759%	25.383867%
Beam + 3-gram (shallow fusion)	10.999756%	3.740129%	55.572289%	25.416306%
Beam + 3-gram (rescoring)	10.999756%	3.754663%	55.060241%	25.405493%

Исходя из таблицы можно сделать вывод, что данная конфигурация модели с любым методом декодирования очень плохо справляется с данными с иным доменом. Довольно очевидно, что метрики стали хуже. Модель имеет низкие вероятности словосочетаний из специфичного домена, поэтому просто не допредсказывает/не может выбрать лучшую по смыслу цепочку, потому что никогда не видела похожих сочетаний, а сочетания в таком специфичном домене могут сильно отличаться от обычных книжных предложений.

9. Задание 7b

Эксперимент с варьированием параметра temperature ∈ {0.5, 1.0, 1.5, 2.0} в методах Greedy и Beam search LM shallow fusion

Рис. 5. Динамика WER для методов декодирования Beam Search shallow fusion и greedy в зависимости от параметра temperature

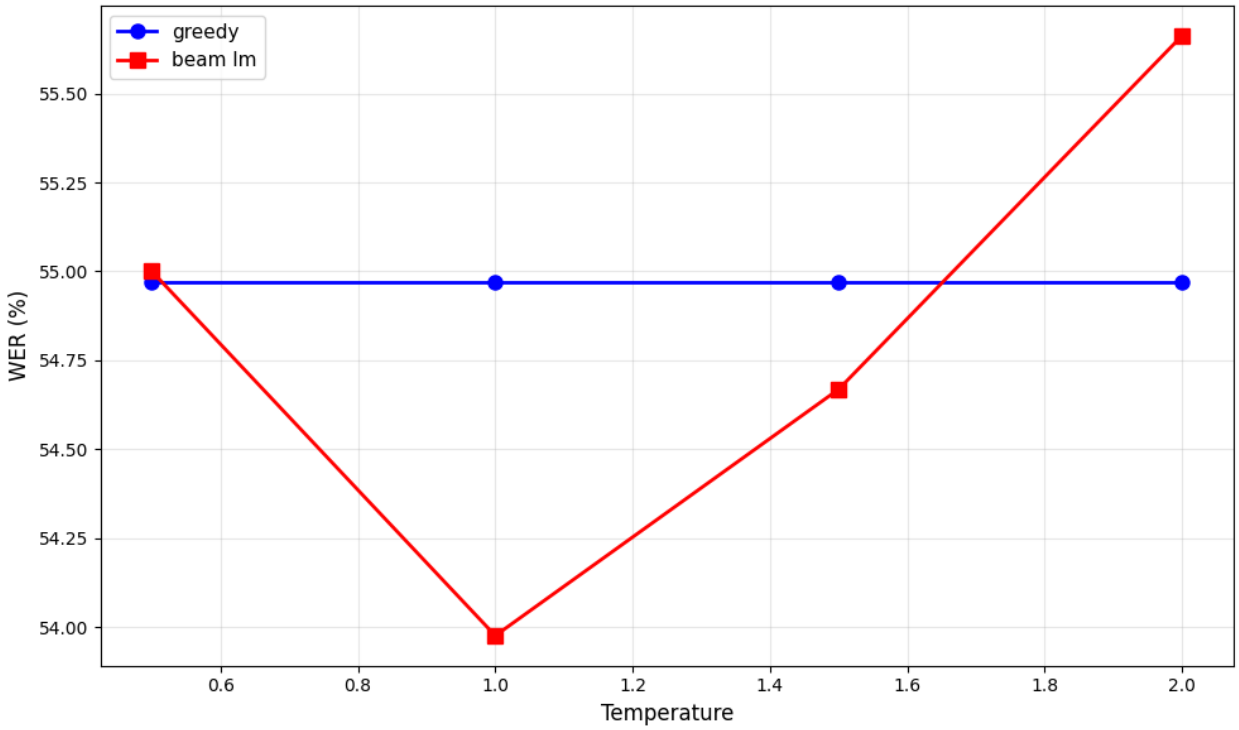

В случае Greedy ничего не изменилось, принцип тот, же поэтому и метрика константная. В случае же shallow fusion разница есть и заметно, что модель показывает себя лучшим образом при temperature = 1.0, т. е. по сути, вообще без действия этого параметра на модель.

10. Задания 8-9

Задания 8-9 подразумевают под собой обучение с нуля LM модели и валидация её на двух датасетах: LibriSpeech и Earnings-22. А также сравнить с работой LibriSpeech 3-gram.
Для обучения новой модели был составлен корпус текста из представленного Earnings-22 train и двух других описанных в пункте Данные.

Все данные были предобработаны:

- Приведение к нижнему регистру;
- Перевод всех цифр в текст;
- Удаление пунктуации

Метод	LibriSpeech WER	LibriSpeech CER	Earnings22 WER	Earnings22 CER

Beam + 3-gram (rescoring)	10.999756%	3.749818%	55.180723%	25.389273%
Beam + 3-gram (shallow fusion)	11.024199%	3.749818%	55.361446%	25.432526%

Даже после обучения новой LM модели на нужном домене результат не изменился. Данный результат может быть связан с тем, что акустическая модель всё равно остается основой модели, а она не переобучена на нужно домене, поэтому метрики на LibriSpeech все ещё хорошие. Для хорошего результата нужно менять акустическую модель.

Кроме того, содержание датасета Earnings22 качества ниже, чем LibriSpeech. В нем содержатся аудио просто буквами (например, когда оператор мычит или «экает», пока думает, в транскрипции это отражено).

P. S. Перед данным результатом также была обучена модель на 5к сэмплов и она имела такой же результат, что и на 1.5 млн. (сейчас), поэтому количество данных для обучения модели не способствует преодолению недообучению.